

视觉大模型在2D姿态估计中的微调与后训练机制研究

引言

近年视觉领域涌现了**视觉基础大模型**用于人体姿态估计等任务。例如，Meta AI 在 2024 年提出的 **Sapiens 模型**，通过在超过 3 亿张人类图像上预训练 Vision Transformer (ViT)，在 2D 人体关键点检测、人体部位分割、深度估计和法线预测四大任务上取得了卓越泛化性能。又如 ViTPose 系列工作，将**纯视觉Transformer**应用于姿态估计并扩展到十亿级参数规模，显示了大模型在姿态估计领域的强大潜力。伴随这些模型的出现，如何**高效微调和后训练 (post-training)** 视觉大模型以适应特定姿态任务，成为当前研究热点。本文围绕近两年 (2024–2025) 顶会发表的代表性工作，从模型微调方法、损失函数设计、指令/反馈机制、数据集设置等方面进行分析，总结这些方法在**视觉-only** (不借助其他模态) 大模型上提升2D姿态估计性能的思路与成果，并探讨其对特定应用 (如婴儿姿态估计) 的启示。

大模型应用于2D姿态估计的代表工作概览

Sapiens: 人体视觉基础模型 (Meta, ECCV 2024) – Sapiens是一系列高分辨率ViT模型，原生支持 1024×1024 图像输入，预训练于 **Humans-300M** (300万张多样人像图片) 数据集。Sapiens采用自监督的Mask Autoencoder (MAE)策略进行预训练，使模型学到对**人类图像**的强表征能力。预训练后，通过**简单微调**即可适配多个下游人体任务：包括2D关键点定位、身体部位分割、深度估计、表面法线预测等。模型采用统一的编码器-解码器架构：编码器初始化为预训练ViT权重，针对每个任务添加轻量解码头并随机初始化，然后对编码器和解码头进行**端到端微调**。这种“预训练+少量调整”的范式带来了**广泛适用性和高保真度**：Sapiens模型可在不同人体部位和比例的图像中泛化，输出精细且高分辨率的结果。在各项人体视觉基准上，Sapiens均大幅超越先前最佳：例如在 Humans-5K 姿态数据集上将 mAP 提升了 **7.6 点**，在 COCO-WholeBody 等数据上取得新的 SOTA。这一工作证明了**大规模人像数据自监督预训练结合下游全量微调**的有效性。

ViTPose & ViTPose++: ViT在人/动物姿态估计中的基线 – ViTPose最初于 2022–2023 年提出，展示了**纯Transformer骨干+轻量解码器**在姿态估计中的强大性能。其结构非常简洁：使用非分层的 Vision Transformer (如ViT-B/L) 作为特征提取骨干，输入单人剪裁图像或全图 (分别对应Top-down或Bottom-up姿态估计范式)，通过**两层反卷积+ 1×1 卷积**构成的解码头输出关键点热图。ViTPose无特殊设计但**可扩展性极强**：参数量从仅2千万扩展到10亿规模时，性能随之提高而架构无需改变。实验证明大模型在COCO等数据集上**精度-速度两全**，10亿参数的单模型在COCO测试集创造了新纪录，同时保持合理推理速度。在此基础上，ViTPose++ 引入了**知识分解和迁移机制**，进一步提升泛化性。具体来说，ViTPose++在Transformer中引入**任务无关与任务特定的前馈网络(FFN)**，使一个模型可以**同时处理多种关键点类别** (如COCO人体、WholeBody全身、动物关键点等)。此外，大模型ViTPose的知识还能通过简单的“知识token”无缝传递给小模型，实现大模型对小模型的蒸馏。ViTPose++ 在一系列数据集上 (COCO、AI Challenger、OCHuman、COCO-WholeBody，以及动物数据集 AP-10K 等) 同时达到当前最优精度。这一系列工作表明：**纯ViT架构结合预训练**在姿态估计中同样高效，大模型的尺度优势和任务灵活性可以通过巧妙的结构改造和知识蒸馏得到充分发挥。

DWPose: 全身姿态两阶段蒸馏 (ICCV 2023 Workshop) – 针对**WholeBody全身姿态估计** (包含人体、手、脚、面部关键点) 的挑战，DWPose提出了一种两阶段知识蒸馏框架，以提升小模型的精度和效率。第一阶段，使用大教师模型 (如 RTMPose-x) 对学生模型 (RTMPose-l) 的**中间特征和最终输出**进行引导训练。与传统仅监督可见关键点不同，DWPose 在蒸馏中利用教师对于**可见和不可见全部关键点**的预测热图作为软目标。此外设计了随训练进行的**蒸馏权重递减策略**，前期充分模仿教师，后期让学生自主学习。第二阶段，被称为**自蒸馏微调**：固定学生模型的主干，只保留其姿态头参与训练。具体做法是拷贝出两个同构学生模型，让其中一个暂作教师，将其**冻结的主干输出**经姿态头得到的预测，作为另一个学生新姿态头的蒸馏目标。这种**仅微调头部**的训练仅需原始20%数据的时间，即可显著提升学生性能。值得注意的是，这种第二阶段方法对任意密集预测头

均通用，可视为部署前的**插拔式性能优化**。凭借两阶段蒸馏，DWPose在COCO-WholeBody取得了**66.5 AP**的新纪录，比原本较大的教师模型精度更高¹²。该工作代表了一种**后训练机制**：在大模型（或现有高精度模型）基础上，通过蒸馏和局部微调，**高效提升小模型**的实用性能。

ProbPose: 概率式姿态估计与奖励损失 (CVPR 2025) – 传统方法输出每个关键点的高斯热图，并用 MSE 损失训练，存在两个局限：(1) 忽略图像外关键点（裁剪或遮挡情况下），训练时将超出图像的关键点当作无效数据舍弃；(2) 预测热图未归一化，无法衡量模型不确定性。来自捷克学者的 ProbPose 引入了**概率地图表示**，创新性地解决了上述问题。模型为每个关键点预测：该点在**窗口内的概率分布**（和为1的归一化热图），**在窗口外的概率**，以及**可见性标签**。这种概率化表示使模型可以输出“未知/在图外”的判断，并校准置信度。从训练角度，ProbPose设计了基于 OKS（目标关键点相似性）的**期望风险损失**。OKS在姿态评估中类似IoU的作用，ProbPose将其融入损失：模型预测的概率分布与真实关键点位置的OKS得分结合，计算期望风险，并通过**最小化预期损失**来直接优化模型对OKS评价指标的表现。换言之，不再简单监督像素误差，而是**对评估指标进行优化**，类似于一种奖励建模。实验结果表明，ProbPose在标准COCO、以及它构造的裁剪数据集CropCOCO上，对**图像边界和以外的**关键点定位显著优于ViTPose等基线³⁴。例如，对于图像被截去一半的人体，ViTPose常误将缺失肢体的位置错配到另一侧，而ProbPose能正确给出该关键点“不在图内”的概率或在图外的合理位置。此外，ProbPose的分布输出在边界附近区域也更为稳健。该方法代表了**损失函数与输出空间设计**的新方向，通过引入**概率论和评价指标**来指导模型训练，可视为一种“软反馈”机制提升模型对复杂情况的处理能力。

大模型微调方法：冻结与解冻、参数高效调整

全量微调 vs. 冻结特征 – 对于大规模预训练模型，经典问题是在下游小数据集上**是否微调全部参数**。Sapiens 和 ViTPose 等工作的经验是：若有足够下游数据，**端到端微调**预训练编码器和新任务头可以取得最佳性能。Sapiens在各个任务上均未冻结ViT主干，而是与解码头一起训练，从而充分利用预训练知识。然而在数据有限或需保持模型泛化时，也有工作探索**部分冻结策略**。例如 DWPose 第二阶段固定了学生模型主干，只微调姿态头，以较小代价获得额外增益。这种做法暗合了实践中常用的“冻结backbone、仅训练最后几层”的策略，在下游数据有限时能防止过拟合。同时它还能作为一种**快速自适应**方法，在模型部署前用少量新数据调整输出层权重而不破坏原有特征。需要注意的是，全量微调虽效果好，但计算和内存开销大；而冻结大部分参数可显著降低训练开销，因此实际应用中常权衡两者以选择合适方案。

LoRA 与 Adapter: 参数高效的插拔微调 – 为减小微调时需更新的参数量，2024 年有多项工作将**参数高效微调** (PEFT)理念引入视觉模型。**LoRA (Low-Rank Adaptation)** 是在预训练权重上添加低秩矩阵调整的技术，只需学习很少的新参数即能达到类似全量微调的效果。在深度估计等视觉任务中，研究者成功将大型ViT冻结，仅在关键层插入LoRA层调节权重，利用不到原模型0.5%的参数就适应了新域。如 EndoDAC 项目中，用DV-LoRA模块结合卷积Neck，使Depth Anything模型高效适配到内窥镜手术场景，在只训练1.6M参数的情况下超越了全量微调方法。类似地，**Adapter** 模块（如两层MLP插入Transformer层中）也被用于调节大型视觉模型在新领域的表现。Chen等人将轻量MLP Adapter插入Segment Anything模型，实现了无提示输入下的医疗图像分割调优。对于姿态估计，虽然2024年前后顶会论文中尚未直接出现“LoRA/Adapter用于姿态模型”的专门研究，但这一思路完全适用。例如，面对**婴儿姿态**这样与成人有较大差异且标注数据稀缺的场景，我们可以考虑冻住在COCO等大数据上预训练的成人姿态模型主干，通过LoRA或Adapter在少量婴儿数据上微调。这将充分利用大模型的通用视觉特征，又避免过拟合稀少的婴儿数据，可视为对**大模型后训练改造**的有前景方向。

知识蒸馏与教师指导 – 除直接微调外，知识蒸馏在大模型适配中扮演重要角色。DWPose 即是通过**大模型教师 - > 小模型学生**的两轮蒸馏，使较小的RTMPose-l获得超过教师的性能¹。第一阶段蒸馏相当于用教师的“**软标签**”（中间特征、全关键点热图）代替人工标注来训练学生，提供了更全面的监督信号。第二阶段的自蒸馏则类似**模型自对齐**(self-alignment)：让模型与自己稍早训练的版本输出对齐。这种策略与语言模型领域的Self-Instruct有共通之处，即利用模型本身的高置信度输出再次提升模型。可以预见，未来姿态估计也可引入**迭代自蒸馏**或**集成自训练**，让模型在无新标注数据情况下，通过与自己或集成模型的预测比较来不断细化（如过滤高置信度预测作为伪标签再训练）。

损失函数设计与反馈信号利用

监督损失的改进 – 人体姿态估计传统上将关键点视作独立点进行L2或L1回归，后来普遍改用**热图回归**（生成高斯热力图，用MSE或softmax + CE损失训练）。然而，正如ProbPose指出的，固定高斯靶图会**限制模型表示的不确定性**，且评估指标OKS与训练目标不一致。ProbPose通过**OKS期望损失**直接优化了评价指标：它定义每个像素预测的OKS得分，将最大化OKS转化为损失最小化的问题，相当于一种**基于奖励的学习**。这种思路类似于强化学习中优化奖励信号，但通过解析形式嵌入损失而非实际RL算法来实现。除此之外，近年来一些姿态方法也探索了特殊损失设计：例如对**不可见关键点**不计入损失或给予特殊权重，鼓励模型学会输出“无此点”；又如利用对称肢体约束、骨骼物理合理性等附加损失，保证预测姿态符合人体结构（这些多在3D姿态估计中采用，在2D领域也有应用）。总的来说，**将先验知识融入损失和直接优化评价指标**是后训练阶段提升模型的重要手段。

人类反馈与指令调优 – 在大模型对齐方面，自然语言处理领域的**RLHF（人类反馈强化学习）**取得了巨大成功。那么在视觉姿态估计中，是否有类似尝试？截至2025年，主流姿态估计工作尚未直接引入人类偏好反馈来训练模型，这与任务性质有关：姿态估计目标明确（准确还原关节位置），评价指标客观统一（例如OKS/AP），不像图像生成或对话那样存在主观偏好需要对齐。然而，一些相关探索在邻近领域出现端倪。例如，研究者已尝试用**直接偏好优化(DPO)**的方法微调扩散模型，以避免显式奖励模型。在**动作生成领域**也有工作使用多重奖励的RL来让生成的3D动作更符合人类偏好和文本语义。类比来看，未来的姿态估计模型或许可以通过**人类反馈**来优化某些特定准则，例如在医疗场景下，让医生反馈模型关键点定位的实用性或稳定性，并据此微调模型参数（这可能需要定义新的奖励函数，比如根据姿态估计对下游任务的贡献评分）。又或者通过**指令学习范式**，让模型能够听从高层指令调整输出，例如“只标注上肢姿态”或“忽略低置信度关键点”等。不过当前这些设想仍未在顶会论文中实现，视觉only模型的指令对齐尚处起步阶段。可以确定的是，**人类在环的训练**会提高模型在特殊人群和复杂动作下的可靠性：对于婴儿姿态估计，研究者完全可以考虑让临床专家参与模型调整，针对模型反复出错的肢体部位给予人工校正反馈，然后通过微调（或强化学习）让模型避免重复错误。这种**后训练增益**并非传统监督数据，而是源自人类偏好的“奖励”信号，将是未来值得探索的方向。

数据集与设置：复杂动作和非标准人群

大模型的训练和微调通常需要多样而丰富的数据集支撑。近年2D姿态估计的重要基准和新数据集包括：

- **COCO Keypoints** – 最广泛使用的人体关键点基准，涵盖日常场景下的多人姿态（17个关键点）。许多方法首先在COCO上预训练或比较性能。
- **COCO-WholeBody** – 扩展了COCO，在人体全身（133个关键点，包括手指和面部）上标注，被DWPose等全身姿态方法采用⁵¹。全身数据弥补了脸部、手势细节，对模型**多尺度部位能力**提出更高要求。
- **MPII、AI Challenger、OCHuman** – MPII和AIC包含日常活动和多人互动场景；OCHuman专注严重遮挡场景。ProbPose的实验特别使用了**OCHuman**及其自建的**CropCOCO**，验证模型在关节出框情况下的表现⁶。结果显示ProbPose在这些极端情况下相对基线提升明显⁴。
- **Humans-300M / Humans-5K / Humans-2K** – Sapiens引入的新数据。其中Humans-300M是用于自监督预训练的无标注大库，涵盖各种人像（包含多人物、多姿态，滤除了水印和非真实人类图像）。Humans-5K和2K则是高质量标注的小型集合，用于评估微调后模型在姿态和分割任务上的泛化。Sapiens在这些集上相对之前方法提升巨大，佐证了**数据分布契合下游任务**的重要性。值得一提的是，Sapiens在预训练数据中保留了**各年龄段、多人互动**等多样性，从而在微调后展现出对不同年龄（包括儿童、老人）和场景的良好泛化。这对婴儿姿态等非标准人群是利好：预训练涵盖广泛人像有助于模型适应婴儿这种体型比例不同的主体。
- **UBody** – 一个包含丰富手势和面部表情的全身数据集，被DWPose用于弥补WholeBody数据中手脸样本的不足⁷。通过在UBody上继续训练，模型对**细粒度局部关节**（手指、眼睛等）的定位精度显著提高。这提示我们，针对特定非标准人群（如婴儿）的姿态估计，也需要专门**收集该人群的精细标注数据**，或利用合成数据增强（例如模拟婴儿不同动作场景），以弥补主流数据集的分布差异。

此外，应用领域的数据也是微调设置的重要考虑。例如**复杂动作场景**（舞蹈、体育运动）可能出现非常规姿态甚至关节超出正常范围的情况，模型若仅在日常数据上训练，遇到此类动作往往会预测错误或漏检。这方面，一些研究采用了**数据合成与增强策略**：利用CG人体模型生成极限姿态图像，或通过随机遮挡、裁剪等增强方法提升模型鲁棒性。ProbPose的**裁剪数据增广**就是一例，通过随机截掉图像局部来生成CropCOCO，从而教会模型识别残缺图像的姿态。结果表明这种增强不仅让模型学会输出“在图外”的判断，还**提升了正常情况下的精度**。

总的来说，大模型微调应**量身定制数据策略**：基础模型先在海量多样数据上获得通用能力，之后微调时再结合目标场景的数据（哪怕很少）进行**针对性校准**。对于婴儿姿态估计，除了利用成人大模型做基础外，理想情况是收集一定量的婴儿关键点数据（或者使用医学合成数据），并在微调过程中施以**特殊损失/约束**（如考虑婴儿肢体柔韧度、常见姿势模式）。正如近期工作所示，高质量的数据和恰当的后训练能够让模型在**非标准人群和复杂动作**下表现出色。

模型后训练改造与展望

视觉大模型为姿态估计提供了新的范式，但直接从大模型到具体应用，中间通常需要**后训练改造**：即在预训练和基本微调完成后，进一步通过特殊机制提升模型在目标领域的性能和可靠性。Sapiens 和 ViTPose 的成功经验首先在于**充分预训练+全面微调**——这奠定了模型强大的基底。在此之上，不同工作针对自身任务施加了定制的后训练步骤：

- **结构改造**：ViTPose++通过在Transformer内部引入任务特定模块，实现一模多能，一次训练满足多任务。这种结构上的后训练改造让模型具备扩展性，日后要适配新姿态类型，只需添加对应的FFN模块即可，而无须推倒重来训练新模型。类似思路可用于婴儿姿态：给模型增加一个“婴儿姿态”分支，在微调时专门学习婴儿骨骼的特征分布，同时共享大部分成人模型权重以利用已有知识。
- **高效微调插槽**：LoRA、Adapter等为模型预留了低成本调节的“插槽”。一旦发现模型在某类数据上表现不佳，我们可以后续再追加一次微调，只训练这些小插槽参数来**矫正模型偏差**。例如如果大模型对婴儿手脚关键点定位偏差较大，我们完全可以在婴儿数据上开启LoRA层再训练几代，从而校正输出分布而不影响模型其他能力。
- **奖励约束优化**：ProbPose的做法相当于**在后训练阶段加入评估指标约束**。这种理念可推广：我们可以根据特定应用关注的指标，在模型已经基本收敛后，再通过类似RL的方式微调使其优化这些指标。例如在临床运动分析中，也许准确检测肢体是否对称比逐点误差更重要，那么可以设计相应损失在后训练时强化对称性。虽然当前顶会论文中鲜有明确提出“RLHF用于姿态估计”，但**直接偏好优化**已经在影像生成等任务证明可行，未来不妨探索将“偏好”定义为“用户对姿态序列平滑、稳定的满意度”等，让模型通过强化学习改善这些维度的表现。
- **知识蒸馏与模型压缩**：DWPose展示了如何在模型训练完毕后，再通过与教师模型的比较来提升或压缩模型。这种**后训练蒸馏**值得在更大模型上尝试。例如，用Sapiens (2B参数) 产生高质量伪标注，去微调一个轻量级姿态网络，以部署在移动设备；或者反过来，用多个强模型的集合输出作为“理想教师”，微调原模型以校正其系统偏差。蒸馏过程也可反复进行，逐步逼近教师性能。

综上，视觉大模型时代的姿态估计不仅依赖**更大、更强的基模**，也仰仗**更聪明的微调与后训练**来落地特定场景。从冻结策略到参数高效插入，从高级损失到人类反馈融入，这些机制为研究者提供了丰富工具箱。对于婴儿姿态这样的前沿应用，我们建议：先利用大模型（如ViTPose、Sapiens）获取强初始模型，再通过**小样本高效微调**和**专门后训练**来雕琢模型，使其掌握婴儿独有的动作模式和临床关切指标。正如Sapiens论文所言，**大数据+大模型**带来泛化和精度，但**精细调整**才能让模型真正服务于每一个独特的场景。未来的研究应继续探索在人类专家的指导下，让视觉模型更深刻地“理解”人类动作，实现从普适智能到专精技能的飞跃。

参考文献:

1. Rawal Khirodkar, et al. “Sapiens: Foundation for Human Vision Models.” ECCV 2024.
2. Yufei Xu, et al. “ViTPose++: Vision Transformer for Generic Body Pose Estimation.” arXiv preprint 2022.
3. Zhendong Yang, et al. “Effective Whole-Body Pose Estimation with Two-Stages Distillation (DWPose).” ICCV Workshops 2023.
4. Miroslav Purkrábek, Jiri Matas. “ProbPose: A Probabilistic Approach to 2D Human Pose Estimation.” CVPR 2025. ³
5. Kai Yang, et al. “Using Human Feedback to Fine-tune Diffusion Models without Any Reward Model.” CVPR 2024.
6. Chen Wei, et al. “Adapter Learning of Foundation Models for Depth Estimation (Surgical-DINO).” MICCAI 2024.

¹ ² ⁵ ⁷ ICCV 2023 Open Access Repository

https://openaccess.thecvf.com/content/ICCV2023W/CV4Metaverse/html/Yang_Effective_Whole-Body_Pose_Estimation_with_Two-Stages_Distillation_ICCVW_2023_paper.html

³ ⁴ ⁶ CVPR Poster ProbPose: A Probabilistic Approach to 2D Human Pose Estimation

<https://cvpr.thecvf.com/virtual/2025/poster/34624>